

Proposta de Estudo Orientado

Regressão Logística - Um singelo resumo

1 O que seria uma Regressão Logística

Regressão logística é uma técnica de IA que visa produzir saídas do tipo “sim”/ “não”, “é”/ “não é”. Nesse trabalho, consideraremos esse tipo de saída como parecer binário. Para emprego dessa técnica pressupõe-se a existência dos seguintes elementos:

- Um conjunto de treino (T), que seja uma amostra dos elementos sobre os quais deverão ser emitidos pareceres binários. Cada elemento desse conjunto deve ser representado por um vetor x_i de dimensão n . A dimensão dos vetores que representam os elementos de teste é conhecida por “natureza”. No caso, a natureza dos elementos sobre os quais se deseja emitir um parecer binário. Desse conjunto, deve-se obter uma matriz X, cujas colunas são formadas pelos vetores x_i , “empilhados”verticalmente”

- Um vetor Y, cujas componentes correspondam aos resultados esperados para cada um dos elementos de X. Se, por exemplo, tivermos um conjunto X, de forma que #X seja 6, Y será um vetor de dimensão 6 em que cada componente guarda o resultado do julgamento esperado sobre o elemento de X correspondente.

- Um vetor w e outro b , de dimensões n , que permitirão mapear cada elemento de X em um vetor Z, da mesma dimensão de Y, dado por $Z = w^T X + b$.

Resumidamente, pode-se afirmar que todo trabalho em torno de uma Regressão Logística se resume em ajustar os vetores w e b de forma que o vetor $\hat{Y} = \sigma(Z)$, esteja cada vez mais próximo de Y. Nas seções a seguir, veremos que, na regressão linear, essa questão é abordada por meio da maximização de uma função probabilidade.

2 A Probabilidade na Regressão Linear

Tornar \hat{Y} mais próximo de Y pode ser alcançado quando cada componente de w produz um vetor Z, em que cada componente maximiza a seguinte função

de probabilidades

$$P(\hat{y}_i = y_i | x = x_i) = \hat{y}_i^{y_i} \cdot (1 - \hat{y}_i)^{(1-y_i)}$$

Façamos os testes:

-Se $y_i = 1$, $P = \hat{y}_i$, que é máxima para $\hat{y}_i = 1$.

-Fica como exercício o caso de $y_i = 0$

Entretanto, matematicamente é mais interessante maximizar $\log(P)$, que é dado por:

$$y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)$$

Em suma, para que w produza \hat{Y} cada vez mais próximos de Y , precisamos ajustar seus valores de forma a maximizar a função $\log(P)$, ou, de forma equivalente minimizar, $L = -\log(P) \iff L = -(y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$. L é conhecida como função custo.

3 Gradient Descent

Para minimizar a função custo (L), a Regressão Logística se utiliza de um algoritmo conhecido por Gradient Descend. Basicamente, omitindo-se inúmeros aspectos formais, dada uma função $f(x)$, esse algoritmo busca o x_n de mínimo, partindo de um valor inicial (x_0). A cada rodado do algoritmo x_{i+1} é obtido somando-se $-\alpha \cdot df/dx$ a x_i , ou seja

$$x_{i+1} = -\alpha \cdot df/dx \quad (1)$$

O parâmetro α é conhecido como passo de aprendizagem. A base desse algoritmo está no fato de a função decrescer quando x toma um sentido contrário ao da derivada. Fica como exercício para o leitor elencar algumas funções em que esse fato pode ser constatado.

No caso específico das Regressões Logísticas, faz-se necessário minimizar a Função Custo (L). As variáveis do domínio são as componentes de w e b . É possível esquematizar a contribuição das componentes de X nas diferenciais das componentes de w , por meio da definição de Z :

$$Z = [w_1 \quad w_2 \quad . \quad w_n] \begin{bmatrix} x_{11} & x_{12} & . & x_{1m} \\ x_{21} & x_{22} & . & x_{2m} \\ x_{31} & x_{32} & . & x_{3m} \\ . & . & . & . \\ . & . & . & . \\ . & . & . & . \\ x_{n1} & x_{n2} & . & x_{nm} \end{bmatrix} + [b_1 \quad b_2 \quad . \quad b_n]$$

Existe uma correspondência linear entre as componentes de X , e as de w , su-

gerida pelo seguinte:

Para w_1

- w_1 está linearmente relacionado a z_1 , por x_{11} como coeficiente;

- w_1 está linearmente relacionado a z_2 , tendo x_{12} como coeficiente;

-...

- w_1 está linearmente relacionado a z_m , tendo x_{1m} como coeficiente;

Para w_2

- w_2 está linearmente relacionado a z_1 , tendo x_{21} como coeficiente;

- w_2 está linearmente relacionado a z_2 , tendo x_{22} como coeficiente;

-...

- w_2 está linearmente relacionado a z_3 , tendo x_{23} como coeficiente;

-...

-...

Para w_n

- w_n está linearmente relacionado a z_1 , tendo x_{n1} como coeficiente;

- w_n está linearmente relacionado a z_2 , tendo x_{n2} como coeficiente;

-... - w_n está linearmente relacionado a z_m , tendo x_{nm} como coeficiente;

Como a relação é linear, a matriz abaixo nos ajuda a visualizar as “componentes” dw

$$\begin{bmatrix} dw_1 & dw_1 & dw_1 & . & . & . & dw_1 \\ dw_2 & dw_2 & dw_2 & . & . & . & dw_2 \\ dw_3 & dw_3 & dw_3 & . & . & . & dw_3 \\ . & . & . & . & . & . & . \\ . & . & . & . & . & . & . \\ . & . & . & . & . & . & . \\ dw_n & dw_n & dw_n & . & . & . & dw_n \end{bmatrix}$$

A partir dessa matriz, pode-se deduzir que:

$$dw_1 = x_{11}dz_1 + x_{12}dz_2... + x_{1m}dz_m$$

Entre b e z , a relação é de coeficiente 1, daí:

$$db = dz_1 + dz_2... + dz_m$$

Da forma como foi definida L , $dz_i = \hat{y}_i - y_i$ Agora, basta aplicarmos o algoritmo, juntando os w e b por meio da equação (1), utilizando um passo de aprendizagem $\frac{\alpha}{m}$